

Mã hóa tường minh

Tiến hóa đa nhiệm dựa trên kỹ thuật tự động mã hóa tường minh

Nhóm 3 - Tiến hóa đa nhiệm

Ngày 19 tháng 11 năm 2023

Mục lục

Giới thiệu: Tiến hóa đa nhiệm

Tối ưu tiến hóa đa nhiệm

Chi tiết triển khai mã hóa

Giới thiệu: Tiến hóa đa nhiệm

Tiến hóa truyền thống

Cơ chế biểu diễn thống nhất

Tối ưu tiến hóa đa nhiệm

Khái quát về tối ưu

Tiến hóa đa nhiệm dựa trên chuyển giao gen ngầm

Tiến hóa đa nhiệm dựa trên chuyển giao gen tường minh

Chi tiết triển khai mã hóa

Quy trình EMT đề xuất

Học ánh giữa các nhiệm vụ

Chuyển giao di truyền giữa các nhiệm vụ

Thuật toán tiến hóa

Thuật toán tiến hóa (Evolutionary Algorithms - EAs) lấy cảm hứng từ nguyên tắc chọn lọc tự nhiên và di truyền học.

- Thuật toán bắt đầu với một quần thể cá thể, trải qua quá trình sinh sản và đột biến để tạo ra thế hệ con cái.
- Quy trình này được thực hiện lặp đi lặp lại và kết thúc khi một điều kiện đã định trước được thỏa mãn.

Nhờ khả năng tìm kiếm mạnh mẽ và dễ sử dụng, EAs đã đạt được những thành công đáng kể trong việc tìm ra lời giải tối ưu hoặc gần tối ưu cho nhiều vấn đề tối ưu hóa phức tạp trong thế giới thực, bao gồm: tối ưu hóa liên tục, tối ưu hóa tổ hợp, tối ưu hóa có ràng buộc, v.v.

Tiến hóa đa nhiệm

Gần đây, lấy cảm hứng từ khả năng đáng chú ý của bộ não con người, có thể thực hiện đồng thời nhiều nhiệm vụ, một mô hình tìm kiếm tiến hóa mới lạ, cụ thể là **Tiến hóa đa nhiệm** (Evolutionary Multitasking - EMT), đã được đề xuất trong lĩnh vực Tính toán tiến hóa.

- EA truyền thống giải quyết một nhiệm vụ trong một lần chạy.
- EMT thực hiện tìm kiếm tiến hóa đồng thời trên nhiều không gian tìm kiếm tương ứng với các nhiệm vụ hoặc vấn đề tối ưu hóa khác nhau.

Bằng cách khai thác sự kết hợp tiềm ẩn giữa các vấn đề tối ưu hóa khác nhau (nhưng lại có thể tương tự), hiệu suất tìm kiếm vượt trội của EMT về chất lượng lời giải và tốc độ hội tụ đã được chứng minh trên một loạt các nhiệm vụ liên tục, rời rạc, hoặc kết hợp liên tục và tổ hợp.

Các thành tựu nghiên cứu

- Gupta *et al.*¹ đã thực hiện mô hình EMT trong lĩnh vực Tối ưu hóa đa mục tiêu (Multiobjective Optimization Problem - MOO).
- Zhou *et al.*² đề xuất một biểu diễn thống nhất dựa trên hoán vị và một toán tử giải mã dựa trên chia tách để thực hiện EMT cho Bài toán Định tuyến phương tiện (Vehicle Routing Problem) thuộc NP-hard.
- Ting *et al.*^{3,4} đã khám phá cơ chế phân bổ tài nguyên để phân bổ lại các đánh giá thích nghi trên con cái của các nhiệm vụ khác nhau và đề xuất một bộ khung chung: Tiến hóa quần xã sinh vật thông qua cộng sinh, cho vấn đề tối ưu hóa nhiều nhiệm vụ (Many-tasking Optimization Problem).

¹Multi-objective multifactorial optimization in evolutionary multitasking

²Evolutionary multitasking in combinatorial search spaces: A case study in capacitated vehicle routing problem

³Parting ways and reallocating resources in evolutionary multitasking

⁴Evolutionary many-tasking based on biocoenosis through symbiosis: A framework and benchmark problems

- Bali *et al.*⁵ đề xuất chiến lược nhằm thay đổi không gian tìm kiếm của một nhiệm vụ đơn giản để nó trở nên tương tự với không gian tìm kiếm của một nhiệm vụ phức tạp hơn, hướng đến việc chuyển giao tri thức tích cực.
- Tang *et al.*⁶ đã giới thiệu một thuật toán EMT để huấn luyện nhiều mô hình máy học cực đại (Extreme Learning Machine - ELM) với số lượng nơ-ron ẩn khác nhau cho các vấn đề phân loại.

⁵Linearized domain adaptation in evolutionary multitasking

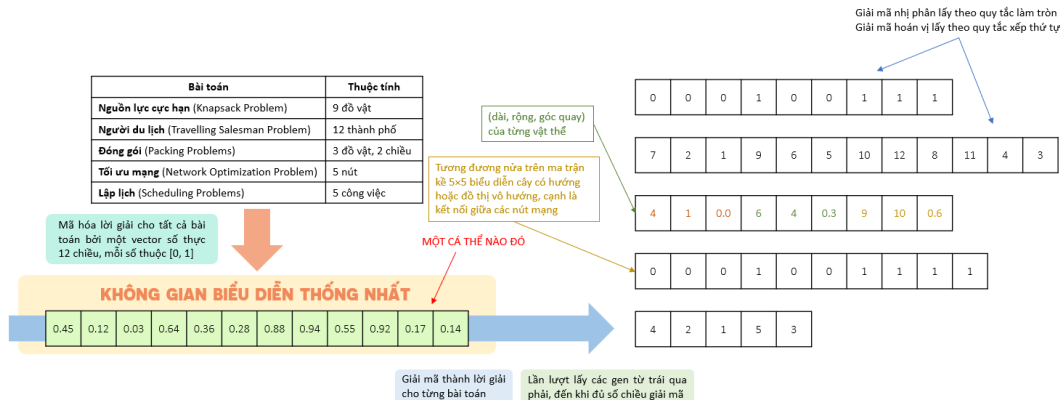
⁶Evolutionary multi-task learning for modular extremal learning machine

Hạn chế của tiến hóa đa nhiệm

- Lưu ý, hầu hết các thuật toán EMT hiện tại đều được thiết kế dựa trên cơ chế biểu diễn lời giải thông nhất.
- Việc chia sẻ kiến thức giữa các nhiệm vụ để giải quyết vấn đề được thực hiện thông qua *sự chuyển giao gen ngầm* trong quá trình lai ghép nhiễm sắc thể.
- Theo cách này, một cơ chế tiến hóa chung (tức là lai ghép và đột biến) thường được thiết kế để giải quyết nhiều nhiệm vụ.

Tuy nhiên, các vấn đề tối ưu hóa khác nhau luôn có những đặc tính cá biệt, có thể yêu cầu các cơ chế tiến hóa khác nhau với độ thiên vị tìm kiếm riêng để giải quyết hiệu quả.

Không gian biểu diễn thông nhất



Hình 1: Minh họa biểu diễn thông nhất cho các bài toán khác nhau

Thiên vị tìm kiếm

Ở đây, *thiên vị tìm kiếm* (search bias) là xu hướng của thuật toán tập trung vào một số khu vực cụ thể trong không gian tìm kiếm hơn là các khu vực khác. Điều này quan trọng vì nó ảnh hưởng đến khả năng của thuật toán để tìm ra lời giải tối ưu.

Các toán tử lai ghép (crossover operators) thường có 2 loại thiên vị: thiên vị vị trí (positional bias) và thiên vị phân phối (distributional bias)⁷.

- **Thiên vị vị trí** ám chỉ xu hướng của toán tử lai ghép ưu tiên trao đổi vật liệu gen dựa trên vị trí của chúng trên nhiễm sắc thể.
- **Thiên vị phân phối** nói đến mức độ mà một số giá trị (vị trí gen cụ thể - loci) có khả năng được truyền trong một sự kiện tái tổ hợp cao hơn các giá trị khác.

⁷Recombination Distributions for Genetic Algorithms

Có nhiều toán tử tiến hóa chuyên biệt với thiên vị tìm kiếm độc đáo, chẳng hạn:

- **Lai ghép đều** (Uniform Crossover): Không tạo ra thiên vị vị trí cũng như thiên vị phân phối. Phù hợp cho bài toán yêu cầu cao về sự đa dạng gen trong quần thể, ví dụ: bài toán có không gian tìm kiếm lớn.
- **Lai ghép một điểm cắt** (One-point Crossover): Phương pháp này có thiên vị vị trí mạnh và có thể gây ra thiên vị phân phối khi các gen quan trọng nằm gần nhau. Phù hợp cho bài toán có các đặc điểm gen được nhóm cùng nhau, ví dụ: bài toán tối ưu đường đi.
- **Lai ghép hai điểm cắt** (Two-point Crossover): Phương pháp này cho phép trao đổi một phần lớn hơn của nhiễm sắc thể giữa cha mẹ, giảm thiên vị vị trí và thiên vị phân phối. Phù hợp cho bài toán tối ưu hóa mà cần duy trì một số đặc điểm gen quan trọng từ cha mẹ, đồng thời cũng muốn tạo ra sự đa dạng trong quần thể con cái.

Nói chung, một toán tử tìm kiếm đặc biệt hữu ích cho một số lớp vấn đề lại khá kém cho các vấn đề khác. Do đó, hướng tới việc cải thiện hiệu suất EMT, với mong muốn là:

- Kết hợp nhiều cơ chế tìm kiếm với thiên vị cụ thể cho từng vấn đề.
- Cho phép chuyển giao kiến thức giữa các nhiệm vụ trong mô hình EMT.

Trong nghiên cứu này, chúng ta khám phá chia sẻ kiến thức giữa các nhiệm vụ trong EMT thông qua *chuyển giao gen tường minh*.

Giới thiệu: Tiến hóa đa nhiệm

Tiến hóa truyền thống

Cơ chế biểu diễn thống nhất

Tối ưu tiến hóa đa nhiệm

Khái quát về tối ưu

Tiến hóa đa nhiệm dựa trên chuyển giao gen ngầm

Tiến hóa đa nhiệm dựa trên chuyển giao gen tường minh

Chi tiết triển khai mã hóa

Quy trình EMT đề xuất

Học ánh giữa các nhiệm vụ

Chuyển giao di truyền giữa các nhiệm vụ

Phân loại vấn đề tối ưu

- Vấn đề tối ưu hóa đơn mục tiêu (SOO): Mỗi điểm trong không gian tìm kiếm tương ứng với một giá trị hàm mục tiêu duy nhất.
- Vấn đề tối ưu hóa đa mục tiêu (MOO): Mỗi điểm trong không gian tìm kiếm tương ứng với một hàm mục tiêu có giá trị vector.

Phần lớn các phương pháp tối ưu hóa hiện tại, đặc biệt là Thuật toán tiến hóa (EAs), được thiết kế để giải quyết một vấn đề tối ưu hóa duy nhất trong một lần chạy, tức là hoặc SOO hoặc MOO.

Tính cần thiết của chia sẻ kiến thức

- Các vấn đề thường không tồn tại một cách riêng rẽ.
- Kiến thức thu được từ việc giải quyết một vấn đề có thể được sử dụng để cải thiện việc tối ưu hóa các vấn đề liên quan

Việc thiết kế phương pháp chia sẻ kiến thức trong tối ưu hóa tiến hóa là mong muốn.

- EMT được đề xuất để thực hiện tìm kiếm tiến hóa trên nhiều vấn đề tối ưu cùng một lúc.
- Lấy cảm hứng từ khả năng đa nhiệm của con người, EMT nhằm cải thiện tính hội tụ cho nhiều vấn đề tối ưu hóa bằng cách chuyển giao kiến thức giữa chúng một cách liền mạch.
- EMT tối ưu hóa đồng thời nhiều nhiệm vụ và khai thác tự động các sự kết hợp tiềm ẩn giữa các vấn đề tối ưu hóa khác nhau, có thể dẫn đến việc giải quyết vấn đề tốt hơn trên tất cả các nhiệm vụ.

Chuyển giao gen ngầm

Hiện tại, hình thức chuyển giao kiến thức trong các thiết kế thuật toán EMT là *chuyển giao gen ngầm* (implicit genetic transfer) thông qua lai ghép nhiễm sắc thể.

Khi thực hiện K nhiệm vụ tối ưu $\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_K$ với hàm mục tiêu tương ứng f_1, f_2, \dots, f_K ; một quần thể cá thể trong không gian biểu diễn thống nhất phải được xác định. Để so sánh các cá thể trong quần thể, các thuộc tính sau của cá thể p thường được định nghĩa trong các phương pháp EMT:


- Factorial Cost. Giá trị hàm mục tiêu ứng với p trên tất cả nhiệm vụ: $(f_1, f_2, \dots, f_K)|_p$
- Factorial Rank. Hạng của p trên tất cả các nhiệm vụ: (r_1, r_2, \dots, r_K)
- Scalar Fitness. Thể hiện xếp hạng tốt nhất của p trên tất cả nhiệm vụ: $\varphi(p) = \min r_i^{-1}$
- Skill Factor. Nhiệm vụ mà p có xếp hạng tốt nhất: $\tau(p) = \arg \min r_i$

Việc so sánh các lời giải có thể được thực hiện một cách rõ ràng dựa trên chỉ số Scalar Fitness. Chẳng hạn, cá thể a được gọi là trội hơn cá thể b theo nghĩa đa nhiệm, nếu $\varphi(a) > \varphi(b)$.

Quy trình xử lý chung của các thuật toán EMT

1. Tạo ra một quần thể ban đầu với N cá thể sử dụng một biểu diễn thống nhất.
2. Đánh giá mỗi cá thể trên tất cả các nhiệm vụ bằng cách tính toán Factorial Cost, Factorial Rank, Scalar Rank, Skill Factor.
3. Áp dụng các **toán tử di truyền**, ví dụ: ghép cặp dựa vào tính tương đồng (assortative mating), trên quần thể hiện tại để tạo ra quần thể con.
 - Vì việc tối ưu hóa nhiều nhiệm vụ dựa trên một quần thể duy nhất, một toán tử di truyền chung được thiết kế để giải quyết các nhiệm vụ khác nhau.
 - Việc chuyển giao di truyền ngầm qua các nhiệm vụ thường được thực hiện thông qua toán tử di truyền này.
4. Đánh giá cá thể con trên các nhiệm vụ được chọn dựa trên văn hóa truyền dọc.
5. Cập nhật Scalar Fitness và Skill Factor của cá thể trong cả quần thể cha mẹ và con.
6. Chọn N cá thể khỏe mạnh nhất dựa trên Scalar Fitness từ cả quần thể cha mẹ và con để tồn tại cho thế hệ tiếp theo.
7. Nếu tiêu chí dừng không được đáp ứng, lặp lại các bước 3 đến 6.

Tóm tắt thuật toán EMT



Hình 2: Lưu đồ thuật toán Tiến hóa đa nhiệm

Bộ tự động mã hóa

Hiện nay, Học sâu có khả năng khám phá cấu trúc phức tạp trong các bộ dữ liệu lớn. Nó đã được áp dụng thành công trong việc giải quyết nhiều vấn đề học máy thách thức, như: phân loại hình ảnh, xử lý ngôn ngữ tự nhiên, học chuyển giao, nhận dạng chữ viết tay, v.v.

Bộ tự động mã hóa (Autoencoders) là một loại mạng nơ-ron nhân tạo được sử dụng trong học không giám sát để nén và tái tạo dữ liệu một cách hiệu quả. Chúng bao gồm 3 lớp (lớp đầu vào, lớp ẩn, lớp đầu ra) với 2 phần chính:

- Bộ mã hóa (encoder): Chuyển đổi dữ liệu đầu vào thành biểu diễn có chiều thấp hơn.
- Bộ giải mã (decoder): Tái tạo dữ liệu gốc từ biểu diễn nén này.

Quá trình huấn luyện của cả encoder và decoder diễn ra đồng thời để giảm thiểu lỗi tái tạo.

Quá trình tự động mã hóa

Với vector đầu vào $\mathbf{x} \in [0, 1]^d$, quá trình mã hóa (encoder) chuyển đổi các mẫu đầu vào để thu được biểu diễn lớp ẩn $\mathbf{y} \in [0, 1]^{d'}$ thông qua ánh xạ $\mathbf{y} = s(W\mathbf{x} + b)$. Trong đó:

- W, b là trọng số và sai số (bias) giữa lớp đầu vào và lớp ẩn.
- s là hàm kích hoạt sigmoid, $s(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{x}}}$.

Quá trình giải mã (decoder) xây dựng lại biểu diễn mã hóa thành vector tái tạo $\mathbf{z} \in [0, 1]^d$ với $\mathbf{z} = s(W'\mathbf{y} + b')$ sao cho $\mathbf{z} \approx \mathbf{x}$. Các tham số của autoencoder, tức là W, W', b, b' được tối ưu hóa để giảm thiểu lỗi tái tạo trung bình như sau:

$$\min_{W, W', b, b'} \frac{1}{n} \sum_{i=1}^n \mathcal{L}(\mathbf{x}_i, \mathbf{z}_i)$$

Trong đó, n là số lượng mẫu dữ liệu và \mathcal{L} là hàm mất mát như sai số bình phương, phân kỳ Kullback–Leibler, v.v.

Bộ tự động mã hóa khử nhiễu

Bộ tự động mã hóa khử nhiễu (Denoising Autoencoders - DAEs) là một biến thể của Autoencoders, được thiết kế để học cách loại bỏ nhiễu khỏi dữ liệu đầu vào.

- Trong DAEs, quá trình huấn luyện bao gồm việc cố ý làm hỏng dữ liệu đầu vào bằng cách thêm nhiễu hoặc che đi một số phần của dữ liệu.
- Sau đó, mô hình được huấn luyện để phục hồi dữ liệu gốc từ phiên bản bị làm hỏng này.
- Điều này giúp DAEs học được cách tập trung vào các đặc điểm quan trọng của dữ liệu, đồng thời loại bỏ các yếu tố không cần thiết hoặc nhiễu.

Kết quả là, DAEs thường tạo ra một biểu diễn ẩn mạnh mẽ và hữu ích, có thể áp dụng trong nhiều tình huống học máy khác nhau, từ giảm chiều dữ liệu, phát hiện bất thường, cho đến chuyển giao kiến thức giữa các lĩnh vực khác nhau.

Chuyển giao gen tường minh

Dựa trên nguyên lý này, DAEs được sử dụng để thực hiện chuyển giao gen rõ ràng trong EMT. Bằng cách coi lời giải của một vấn đề thuộc lĩnh vực này như phiên bản bị làm hỏng của lời giải đối với vấn đề thuộc lĩnh vực khác, quá trình khử nhiễu có thể tạo ra một kết nối giữa hai lĩnh vực.

Cụ thể, gọi $\mathcal{P} = \{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_N\}$ và $\mathcal{Q} = \{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_N\}$ đại diện cho tập hợp các lời giải được lấy mẫu đồng đều và độc lập từ không gian tìm kiếm của hai vấn đề tối ưu hóa khác nhau là OP_1 và OP_2 . Kết nối từ OP_1 sang OP_2 có thể được xây dựng một cách tự nhiên thông qua Bộ tự động mã hóa khử nhiễu bằng cách sử dụng \mathcal{P} làm đầu vào và \mathcal{Q} làm đầu ra.

Để đơn giản, các đầu vào bị làm hỏng được tái tạo bởi một ánh xạ đơn cấp $\mathcal{M} : \mathbb{R}^d \rightarrow \mathbb{R}^d$ mà tối thiểu sai số bình phương:

$$\mathcal{L}_{\text{sq}}(\mathcal{M}) = \frac{1}{2N} \sum_{i=1}^N \|\mathbf{p}_i - \mathcal{M}\mathbf{q}_i\|_2^2$$

Ở đây, đã bổ sung hằng số đặc trưng $\mathbf{p}_i = [\mathbf{p}_i, 1]$ và $\mathbf{q}_i = [\mathbf{q}_i, 1]$ và sai số $\mathcal{M} = [\mathcal{M}, b]$.

Nghiệm tổng quát là $\mathcal{M} = (QP^\top)(PP^\top)^{-1}$.

Chuyển giao các lời giải từ OP_1 sang OP_2 được thực hiện đơn giản bằng phép nhân với \mathcal{M} .

Giới thiệu: Tiến hóa đa nhiệm

Tiến hóa truyền thống

Cơ chế biểu diễn thống nhất

Tối ưu tiến hóa đa nhiệm

Khái quát về tối ưu

Tiến hóa đa nhiệm dựa trên chuyển giao gen ngầm

Tiến hóa đa nhiệm dựa trên chuyển giao gen tường minh

Chi tiết triển khai mã hóa

Quy trình EMT đề xuất

Học ánh giữa các nhiệm vụ

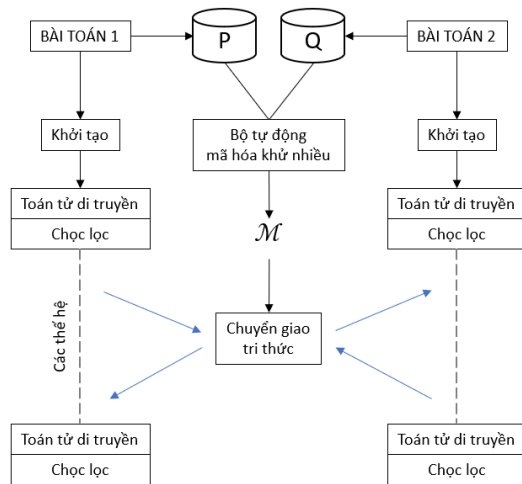
Chuyển giao di truyền giữa các nhiệm vụ

Mô hình EMT đề xuất

Để giải quyết đồng thời hai nhiệm vụ tối ưu hóa, tức là OP_1 và OP_2 , mô hình EMT đề xuất diễn ra như sau:

1. Hai trình giải quyết tiến hóa riêng biệt với quần thể độc lập được sử dụng.
2. Tiếp theo, để xây dựng kết nối giữa các nhiệm vụ, hai tập hợp lời giải được lấy mẫu đồng đều và độc lập từ không gian tìm kiếm của OP_1 và OP_2 , sau đó được sử dụng làm đầu vào và đầu ra cho DAEs để thu được ánh xạ \mathcal{M} .
3. Các lời giải tốt tìm thấy bởi bất kỳ trình giải quyết nào trong quá trình tìm kiếm có thể được chuyển giao và tiêm vào quần thể của trình giải quyết kia thông qua phép nhân với ánh xạ đã học \mathcal{M} .
4. Các quần thể của cả hai trình giải quyết với các lời giải được tiêm vào sẽ trải qua quá trình chọn lọc tự nhiên và tái sản xuất cho đến khi một tiêu chí dừng nhất định được thỏa mãn.

Như vậy, chuyển giao di truyền tường minh xảy ra cùng với quá trình tìm kiếm của hai trình giải quyết tiến hóa.



Hình 3: Sơ đồ chuyển giao tri thức giữa hai bài toán

Lưu ý rằng, mô hình EMT được đề xuất khác với Đồng tiến hóa hợp tác (Cooperative Coevolution - CC). Mặc dù cả hai đều chứa nhiều trình giải quyết tiến hóa, tuy nhiên:

- Mô hình EMT được đề xuất giải quyết nhiều nhiệm vụ với các mục tiêu khác nhau.
- Đồng tiến hóa hợp tác giải quyết một nhiệm vụ với một mục tiêu chung

Học ánh xạ giữa hai nhiệm vụ

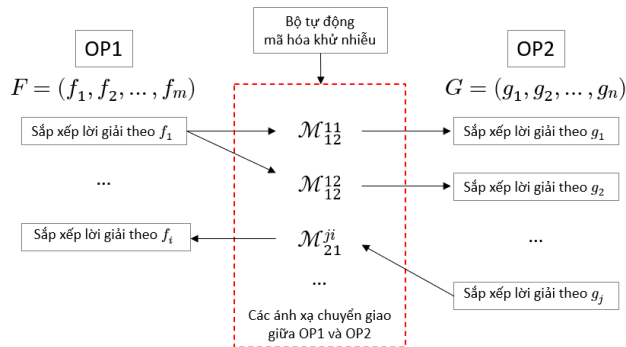
Thuật toán 1: Learning of Task Mapping

Input: OP_1 và OP_2 là hai bài toán tối ưu với hàm mục tiêu, miền xác định của chúng.

Output: \mathcal{M}_{12} là ánh xạ chuyển giao từ OP_1 sang OP_2 .

1. Lấy mẫu đồng đều và độc lập hai tập hợp P, Q , mỗi tập hợp gồm N lời giải dựa trên miền giá trị của OP_1 và OP_2 tương ứng.
2. Sắp xếp các lời giải trong P và Q theo giá trị hàm mục tiêu của chúng.
3. Coi P và Q tương ứng là đầu vào và đầu ra cho Bộ tự động mã hóa khử nhiễu.
4. Thu được ánh xạ \mathcal{M}_{12} .

- Trong trường hợp hai nhiệm vụ có kích thước khác nhau, chúng ta sẽ thêm các giá trị 0 vào các lời giải tương ứng để cả hai có cùng kích thước chiều.
- Trong trường hợp P và Q là các bài toán Tối ưu đa mục tiêu, sẽ có nhiều ánh xạ từ OP_1 sang OP_2 . Mỗi ánh xạ \mathcal{M}_{12}^{ij} tương ứng chuyển giao lời giải dựa trên mục tiêu thứ i của OP_1 sang lời giải dựa trên mục tiêu thứ j của OP_2 .



Hình 4: Minh họa các ánh xạ chuyển giao trong trường hợp Tối ưu đa mục tiêu

Chuyển giao di truyền tường minh

- Bên cạnh việc học ánh xạ giữa các nhiệm vụ, cách thực hiện chuyển giao di truyền tường minh trong SOO và MOO là một vấn đề then chốt khác trong mô hình EMT được đề xuất.
- Cụ thể, khi nào thì chuyển giao xảy ra và những gì cần chuyển giao giữa các nhiệm vụ phải được thiết kế cụ thể.

Thuật toán 2: Explicit Genetic Transfer

Input: OP_1 và OP_2 là hai bài toán tối ưu đa mục tiêu.

Output: Chuyển giao lời giải giữa OP_1 và OP_2 .

1. Chọn ngẫu nhiên hàm mục tiêu a từ OP_1 và b từ OP_2 .
2. Chọn S lời giải tốt nhất đối với hàm a trong quần thể từ trình tiến hóa giải OP_1 và S lời giải tốt nhất đối với hàm b trong quần thể từ trình tiến hóa giải OP_2 .
3. Chuyển giao các lời giải được chọn từ OP_1 sang OP_2 dựa vào ánh xạ \mathcal{M}_{12}^{ab} và từ OP_2 sang OP_1 dựa vào ánh xạ \mathcal{M}_{21}^{ba} .

- Đối với SOO:
 - i Chuyển giao kiến thức giữa các nhiệm vụ diễn ra sau một khoảng thời gian nào đó, có thể cố định hoặc với tần suất phức tạp hơn.
 - ii Mỗi khi chuyển giao, S lời giải tốt nhất của nhiệm vụ này được chuyển qua nhiệm vụ kia, thông qua phép nhân ánh xạ đã học \mathcal{M} .
- Đối với MOO:
 - i Thời gian chuyển giao thiết kế tùy chọn.
 - ii Do có nhiều hàm mục tiêu, mỗi lần chuyển giao, S lời giải tốt nhất của một trình giải quyết được chuyển sang trình giải quyết khác tương ứng với một cặp hàm mục tiêu được chọn ngẫu nhiên.